

Efecto de la dilución aleatoria en el aprendizaje automático profundo con redes neuronales *feed-forward*

Regularización estocástica mediante Dropout, DropConnect y BoostDropout

Gamalerio Joaquín Ignacio

Facultad de Matemática, Astronomía, Física y Computación
Universidad Nacional de Córdoba
Director: Dr. Francisco A. Tamarit

Mayo, 2026

Motivación: Queremos que la red aprenda, no que memorice.


- ▶ Una red neuronal aprende mirando siempre ejemplos conocidos.
- ▶ El objetivo no es solo que acierte esos ejemplos, sino que también funcione bien con ejemplos nuevos, que no ve durante el aprendizaje.
- ▶ A veces la red “memoriza” detalles del entrenamiento en lugar de aprender patrones útiles.
- ▶ Cuando eso ocurre, su desempeño baja frente a datos que nunca vio.
- ▶ Este problema se llama **sobreajuste**.
- ▶ La tesis estudia cómo reducirlo induciendo perturbaciones en la red durante el aprendizaje.

Objetivos de la tesis


- ▶ Estudiar cómo mejorar el desempeño de redes neuronales frente a datos nuevos.
- ▶ Comparar una red base con dos métodos conocidos: *Dropout* y *DropConnect*.
- ▶ Proponer y evaluar *BoostDropout*, una variante que modifica la intensidad de algunas señales internas.
- ▶ Analizar si estas perturbaciones ayudan a reducir el **sobreajuste**.
- ▶ Usar un autoencoder para observar las representaciones aprendidas y estudiar su **esparsidad**.

De una neurona a una red *feed-forward*

Perceptrón simple




Red *feed-forward*



Idea

Una neurona transforma información de entrada en una señal de salida.

Diagrama de entrenamiento



Resumen

Entrenamiento ajusta los pesos. Validación ayuda a elegir hiperparámetros de entrenamiento. Test se usa solo al final para evaluar datos no vistos.

Sobreajuste y generalización


Sobreajuste:

- Hay sobreajuste cuando el **error de test** es muy alto comparado con el **error de entrenamiento**

Diagnóstico temprano:

- La **pérdida de entrenamiento** puede seguir bajando.
- La **pérdida de validación** puede dejar de mejorar y comenzar a subir.

Curvas de loss durante entrenamiento




¿Qué es la regularización?

¿Qué entendemos por dilución y perturbación en el entrenamiento?


Dropout y DropConnect: dilución aleatoria

Dropout



$$\tilde{h} = m \odot h/p$$

DropConnect



$$\tilde{W} = M \odot W/p$$

Idea central

Dropout y DropConnect son dos estrategias de dilución aleatoria durante el entrenamiento.


BoostDropout: idea central

Máscara propuesta

$$m_j = \begin{cases} 1 + \lambda, & \text{con probabilidad } p, \\ 1, & \text{con probabilidad } 1 - p, \end{cases}$$


$$\tilde{h}_j = m_j h_j$$

BoostDropout durante training



$$\tilde{h} = \hat{m} \odot h$$

Comparación de métodos de regularización en redes neuronales *feed-forward*



- ▶ MNIST como tarea de clasificación supervisada.
- ▶ Arquitectura compartida para todas las redes comparadas.
- ▶ Fase 1: exploración de hiperparámetros y selección por validación.
- ▶ Fase 2: evaluación final multisentilla con configuraciones fijadas.

MMV

- ▶ Mejor modelo según pérdida de validación.
- ▶ Selecciona el modelo que alcanza la menor pérdida de validación durante todo el entrenamiento.

Early stopping

- ▶ Modelo elegido por una política de detención temprana.
- ▶ Usa pérdida de validación como métrica y una tolerancia definida.

Configuraciones seleccionadas

Hiperparámetros compartidos



Decisión	Uso en el experimento
Optimizador	Adam.
Batch size	256.
Activación	ReLU en capas ocultas.
Pérdida	Entropía cruzada para clasificación multiclase.
Validación	Selección de hiperparámetros y artefactos.
Test	Reservado para evaluación final.

Hiperparámetros de la búsqueda en grilla



Modelo	p explorado	λ explorado	Normalización explorada
<i>DropoutNet</i>	0.1, 0.3, 0.5, 0.7, 0.9	–	–
<i>DropConnectNet</i>	0.1, 0.3, 0.5, 0.7, 0.9	–	–
<i>BoostDropoutNet</i>	0.1, 0.3, 0.5, 0.7, 0.9	-0.6, -0.3, 0.0, 0.3, 0.6, 0.9	True, False

Resultados de experimentación Principal

Resultado global: criterio MMV




Resultado global: *early stopping*




Distribución de la mejor época

Mejor época MMV




Mejor época *early stopping*




Curvas representativas de validación (MMV)

Error de validación




Pérdida de validación




Dependencia con p (MMV)

Error de test




Pérdida de test




Dependencia con p (*early stopping*)

Error de test




Pérdida de test




Dependencia con λ (MMV)

Error de test




Pérdida de test




Dependencia con λ (*early stopping*)

Error de test




Pérdida de test



Conclusión del protocolo principal

- ① La regularización estocástica mejora sistemáticamente a la red base.
- ② Dropout y DropConnect reducen el sobreajuste y obtienen resultados similares entre sí.
- ③ *BoostDropoutNet* supera a las tres arquitecturas de referencia en error y pérdida de test.
- ④ La ventaja se sostiene bajo MMV, *early stopping*, curvas temporales y análisis de sensibilidad.

Experimentación secundaria: Autoencoders




- ▶ Entrenar autoencoders con MNIST.
- ▶ Comparar las mismas estrategias de regularización.
- ▶ Analizar esparsidad representacional y paramétrica.
- ▶ Observar características aprendidas.


Resultados de experimentación secundaria con autoencoders

Visualización de coadaptaciones: autoencoder base y con Dropout

Coadaptaciones autoencoder base




Coadaptaciones Dropout




Visualización de coadaptaciones: con DropConnect y BoostDropout

Coadaptaciones DropConnect




Coadaptaciones BoostDropout




Decodificaciones latentes: autoencoder base y con Dropout

Decodificaciones autoencoder base




Decodificaciones Dropout




Decodificaciones latentes: con DropConnect y BoostDropout



Decodificaciones DropConnect



Decodificaciones BoostDropout




Esparcidad representacional: autoencoder base y con Dropout




Esparsidad representacional: con DropConnect y BoostDropout

Esparsidad DropConnect




Esparsidad BoostDropout




Esparsidad paramétrica: autoencoder base y con Dropout

Esparsidad autoencoder base




Esparsidad Dropout




Esparsidad paramétrica: con DropConnect y BoostDropout

Esparsidad DropConnect



Esparsidad BoostDropout



Conclusiones Generales

- 1 El sobreajuste aparece como una limitación central en redes neuronales con alta capacidad expresiva.
- 2 Dropout y DropConnect reducen este problema introduciendo dilución aleatoria durante el entrenamiento.
- 3 En esta tesis se propuso *BoostDropout*, una alternativa que reemplaza la supresión binaria por una modulación multiplicativa de las activaciones.
- 4 En el protocolo experimental estudiado, *BoostDropoutNet* obtuvo menor error y menor pérdida de test que la red base, Dropout y DropConnect.
- 5 La contribución principal es mostrar que la regularización estocástica puede pensarse más allá de “apagar” neuronas o conexiones.

Próximos pasos

- ▶ Evaluar *BoostDropout* en otros conjuntos de datos.
- ▶ Probar arquitecturas más profundas y convolucionales.
- ▶ Explorar con mayor detalle el espacio de p , λ y normalización.
- ▶ Analizar calibración, estabilidad y dinámica de entrenamiento.
- ▶ Estudiar variantes de máscaras multiplicativas más generales.

Mensaje final

***BoostDropout* no cierra el problema de la regularización: propone una dirección para explorarlo.**

¡Muchas gracias!