

Efecto de la dilución aleatoria en el aprendizaje automático profundo con redes neuronales *feed-forward*

Regularización estocástica mediante Dropout, DropConnect y BoostDropout

Gamalerio Joaquín Ignacio

Facultad de Matemática, Astronomía, Física y Computación
Universidad Nacional de Córdoba
Director: Dr. Francisco A. Tamarit

Mayo, 2026

¿Puede una perturbación estocástica no binaria mejorar la regularización de redes neuronales *feed-forward*?

Sobreajuste

Regularización

BoostDropout

Mensaje central

La tesis pregunta qué ocurre si la dilución estocástica no solo apaga unidades o conexiones, sino que también puede modular la intensidad de las señales internas.

Mapa narrativo de la defensa

- ❶ **Problema:** las redes con alta capacidad expresiva pueden memorizar y no generalizar.
- ❷ **Herramientas clásicas:** Dropout y DropConnect introducen dilución estocástica binaria.
- ❸ **Propuesta:** *BoostDropout* reemplaza la supresión binaria por modulación multiplicativa de activaciones.
- ❹ **Evaluación:** comparación controlada en MNIST con varias semillas.
- ❺ **Resultado:** *BoostDropoutNet* mejora la generalización en el protocolo estudiado.

Alcance

No se busca demostrar superioridad universal, sino evaluar una idea nueva en un escenario controlado y reproducible.

Motivación: aprender no es suficiente

- ▶ Una red neuronal puede tener muchos parámetros y alta capacidad expresiva.
- ▶ Eso le permite capturar regularidades complejas.
- ▶ Pero también puede aprender fluctuaciones particulares del conjunto de entrenamiento.

Mensaje central

El objetivo no es minimizar solamente el error de entrenamiento: el objetivo es generalizar.

Imagen pendiente

15_curvas_loss_overfitting.png

Imagen sugerida de la tesis:

15_curvas_loss_overfitting.png

Aporte principal

Se propone y estudia *BoostDropout*, un mecanismo de regularización estocástica basado en una modulación multiplicativa no binaria de activaciones.

- ▶ Se compara contra una red base sin regularización estocástica.
- ▶ Se contrasta con dos regularizadores clásicos: Dropout y DropConnect.
- ▶ Se evalúa con un protocolo controlado sobre MNIST, usando búsqueda de hiperparámetros y evaluación final multisesemilla.

Modelo	Regularización
<i>OverFitNet</i>	Ninguna
<i>DropoutNet</i>	Dropout
<i>DropConnectNet</i>	DropConnect
<i>BoostDropoutNet</i>	<i>BoostDropout</i>

Redes *feed-forward*: de una unidad a muchas capas

Perceptrón simple

Imagen pendiente

01_perceptron_simple.png

Perceptrón multicapa

Imagen pendiente

02_perceptron_multicapa.png

Imagen sugerida de la tesis: 01_perceptron_simple.png

Imagen sugerida de la tesis: 02_perceptron_multicapa.png

Mensaje central

Una red *feed-forward* compone transformaciones capa por capa: entrada → representaciones internas → salida


Clasificación supervisada en MNIST

- ▶ Entrada: imagen de 28×28 píxeles, vectorizada en 784 componentes.
- ▶ Salida: una clase entre 0 y 9.
- ▶ La red produce *logits*; la decisión final se toma por la clase de mayor puntaje.
- ▶ La pérdida usada es entropía cruzada.



Imagen sugerida de la tesis: mnist_ejemplos.png

Entrenamiento de la red



- ▶ La retropropagación calcula gradientes aplicando regla de la cadena.
- ▶ Adam actualiza parámetros de manera adaptativa.
- ▶ La validación permite seleccionar modelos sin tocar el conjunto de test.

Conceptos técnicos usados en el experimento

Elemento	Rol en el protocolo
ReLU	Activación no lineal en capas ocultas.
Entropía cruzada	Pérdida adecuada para clasificación multiclase.
Adam	Optimizador adaptativo usado para entrenar.
Entrenamiento/validación/test	Separación entre ajuste, selección y evaluación final.
Early stopping	Criterio alternativo para seleccionar un artefacto durante entrenamiento.
Múltiples semillas	Control de variabilidad por inicialización y aleatoriedad.

Imagen pendiente

15_curvas_loss_overfitting.png

Imagen sugerida de la tesis:

15_curvas_loss_overfitting.png

- ▶ La pérdida de entrenamiento puede seguir bajando.
- ▶ La pérdida de validación puede dejar de mejorar y comenzar a subir.
- ▶ Esa brecha indica que la red empieza a capturar detalles que no se transfieren a datos nuevos.

Diagnóstico práctico

El sobreajuste se observa cuando mejorar el ajuste al entrenamiento deja de mejorar la validación.

Regularización: idea general

Definición operativa

Regularizar es modificar el aprendizaje para reducir el error de generalización, aunque eso no implique reducir el error de entrenamiento.

Sin regularización

- ▶ Mayor libertad efectiva.
- ▶ Más riesgo de dependencia de patrones frágiles.
- ▶ Sobreajuste más visible.

Con regularización estocástica

- ▶ Se perturba la propagación durante entrenamiento.
- ▶ La red debe distribuir información de modo más robusto.
- ▶ Se busca mejor desempeño fuera de muestra.

Dropout: apagar activaciones

- ▶ En cada pasada de entrenamiento, una fracción de activaciones se anula aleatoriamente.
- ▶ La perturbación es binaria: cada activación queda activa o apagada.
- ▶ La red no puede depender rígidamente de unidades específicas.
- ▶ Se interpreta como entrenamiento de muchas subredes implícitas con pesos compartidos.

Imagen pendiente

dropconnect y
dropout/10_inverted_dropout_training.png

Imagen pendiente

dropconnect y
dropout/11_inverted_dropout_inferencia.p

DropConnect: apagar conexiones

- ▶ La máscara aleatoria actúa sobre pesos individuales, no sobre neuronas completas.
- ▶ La activación puede existir, pero algunas conexiones salientes o entrantes se anulan.
- ▶ La conectividad efectiva cambia en cada iteración.
- ▶ También es una perturbación binaria.

Imagen pendiente

dropconnect y
dropout/12_dropconnect_training.png

Imagen pendiente

dropconnect y
dropout/13_dropconnect_inferencia.png

Dropout vs DropConnect

Método	Qué perturba	Máscara	Intuición
Dropout	Activaciones	Binaria	Apaga neuronas durante entrenamiento.
DropConnect	Pesos/conexiones	Binaria	Apaga enlaces individuales.

Mensaje central

Ambos métodos diluyen estocásticamente la red, pero actúan en niveles distintos de la arquitectura.

BoostDropout: idea central

- ▶ No apaga necesariamente la señal.
- ▶ Modula multiplicativamente la activación.
- ▶ Reemplaza “apagar/conservar” por “modificar amplitud”.
- ▶ Introduce dos hiperparámetros principales: frecuencia p e intensidad λ .

Máscara propuesta

$$m_j = \begin{cases} 1 + \lambda, & \text{con probabilidad } p, \\ 1, & \text{con probabilidad } 1 - p. \end{cases} \quad \tilde{h}_j = m_j h_j$$

Imagen pendiente
14_boostdropout_training.png

Imagen sugerida de la tesis:

14_boostdropout_training.png

Máscara normalizada y vínculo con Dropout

- ▶ El valor esperado de la máscara es

$$\mathbb{E}[m_j] = 1 + p\lambda.$$

- ▶ Si se quiere preservar la escala esperada, puede usarse

$$\hat{m}_j = \frac{m_j}{1 + p\lambda}, \quad \mathbb{E}[\hat{m}_j] = 1.$$

- ▶ Si $\lambda = -1$, la máscara pasa a ser binaria sobre $\{0, 1\}$.
- ▶ Con normalización adecuada, ese caso recupera la lógica de *inverted dropout*.

Diferencia clave

En esta tesis, la configuración seleccionada de *BoostDropout* usa $p = 0.7$, $\lambda = 0.9$ y máscara no normalizada.

Tres métodos en una misma familia

Método	Nivel de acción	Tipo de perturbación	Lectura conceptual
Dropout	Activaciones	Binaria	Supresión aleatoria de unidades.
DropConnect	Conexiones	Binaria	Supresión aleatoria de pesos.
<i>BoostDropout</i>	Activaciones	No binaria / multiplicativa	Modulación estocástica de amplitud.

Mensaje central

La propuesta conserva la idea de perturbar la red durante entrenamiento, pero amplía el tipo de perturbación posible.

Objetivo experimental

Comparar si *BoostDropout* mejora la generalización frente a una red base y frente a regularizadores clásicos bajo condiciones controladas.

<i>OverFitNet</i>	<i>DropoutNet</i>	<i>DropConnectNet</i>	<i>BoostDropoutNet</i>
Sin reg.	Dropout	DropConnect	<i>BoostDropout</i>

Principio de comparación

Todas las arquitecturas comparten la misma topología base; cambia únicamente el mecanismo de regularización.

Dataset: MNIST y subconjunto controlado

Imagen pendiente
`mnist_ejemplos.png`

- ▶ MNIST: dígitos manuscritos de 0 a 9.
- ▶ Imágenes de 28×28 píxeles.
- ▶ Se usa un subconjunto estratificado.
- ▶ El subset reduce costo computacional y vuelve visible el sobreajuste.

Decisión metodológica

El objetivo no fue maximizar el rendimiento absoluto en MNIST, sino estudiar regularización en un escenario controlado.

Imagen sugerida de la tesis: `mnist_ejemplos.png`

Arquitectura base

Topología común

784 → 256 → 256 → 256 → 10

- ▶ Red densa *feed-forward*.
- ▶ Capas ocultas con ReLU.
- ▶ Salida de 10 clases.
- ▶ Misma arquitectura para los cuatro modelos comparados.

Imagen pendiente

arquitectura_base_regularizada_limpia.png

Imagen sugerida de la tesis:

arquitectura_base_regularizada_limpia.png

Modelos comparados

Modelo	Descripción
<i>OverFitNet</i>	Arquitectura base sin regularización estocástica.
<i>DropoutNet</i>	Misma arquitectura con Dropout en capas ocultas.
<i>DropConnectNet</i>	Misma arquitectura con DropConnect en capas densas.
<i>BoostDropoutNet</i>	Misma arquitectura con modulación multiplicativa <i>BoostDropout</i> .

Mensaje central

La comparación se concentra en el mecanismo de regularización, no en cambiar tamaño, profundidad o dataset.

Protocolo de entrenamiento

Decisión	Uso en el experimento
Optimizador	Adam.
Batch size	256.
Activación	ReLU en capas ocultas.
Pérdida	Entropía cruzada para clasificación multiclase.
Validación	Selección de hiperparámetros y artefactos.
Test	Evaluación final reservada.

Separación estricta

El test no interviene en la búsqueda de hiperparámetros ni en la selección de modelos.

Dos fases experimentales

Fase 1: exploración

- ▶ Grid search de hiperparámetros.
- ▶ Varias semillas.
- ▶ Selección por validación.

Fase 2: evaluación final

- ▶ Configuraciones fijadas.
- ▶ Entrenamiento multisevilla.
- ▶ Reporte en validación y test.

Mensaje central

La evaluación multisevilla evita que una corrida afortunada defina la conclusión.

Criterios de selección: MMV y *early stopping*

MMV

Mejor modelo según pérdida de validación.
Permite seleccionar el mínimo observado durante el entrenamiento.

Early stopping

Artefacto elegido por una política de detención temprana, usando validación como señal.

Por qué usar ambos

Comparar ambos criterios permite verificar si la conclusión depende del modo de seleccionar el modelo final.

Configuraciones seleccionadas

Modelo	p	λ	Normalización
<i>DropoutNet</i>	0.5	–	–
<i>DropConnectNet</i>	0.5	–	–
<i>BoostDropoutNet</i>	0.7	0.9	No

Mensaje central

La configuración seleccionada de *BoostDropout* corresponde a una modulación frecuente, positiva y no normalizada.

Resultado global: criterio MMV

Imagen pendiente

imagenes_resultados/entrenamiento_principal/best_model/boxplot_error_test_best_model

Modelo	Error test	Pérdida test
<i>OverFitNet</i>	0.0687	0.2311
<i>DropoutNet</i>	0.0609	0.2129
<i>DropConnectNet</i>	0.0614	0.2133
<i>BoostDropoutNet</i>	0.0480	0.1598

Lectura

Bajo MMV, *BoostDropoutNet* obtiene menor error y menor pérdida media de test.

Imagen pendiente

imagenes_resultados/entrenamiento_principal/best_model/boxplot_perdida_test_best_model

Interpretación del resultado MMV

- ▶ *OverFitNet* presenta el peor desempeño: el sobreajuste afecta la generalización.
- ▶ *DropoutNet* y *DropConnectNet* mejoran respecto de la red base.
- ▶ Ambos regularizadores clásicos quedan muy cercanos entre sí.
- ▶ *BoostDropoutNet* desplaza la distribución hacia valores menores de error y pérdida.

Mensaje central

La mejora de *BoostDropoutNet* no aparece solo en un valor medio aislado: también se observa en medianas, boxplots y métricas de validación.

Resultado global: *early stopping*

Imagen pendiente

imagenes_resultados/entrenamiento_principal/early_stopping/boxplot_error_test_early

Modelo	Error test	Pérdida test
<i>OverFitNet</i>	0.0687	0.2310
<i>DropoutNet</i>	0.0609	0.2129
<i>DropConnectNet</i>	0.0614	0.2133
<i>BoostDropoutNet</i>	0.0491	0.1640

Lectura

El patrón se conserva: *BoostDropoutNet* sigue siendo el mejor modelo dentro del protocolo.

Imagen pendiente

imagenes_resultados/entrenamiento_principal/early_stopping/boxplot_perdida_test_ear

MMV vs *early stopping*

Modelo	Error test MMV	Error test <i>early stopping</i>
<i>OverFitNet</i>	0.0687	0.0687
<i>DropoutNet</i>	0.0609	0.0609
<i>DropConnectNet</i>	0.0614	0.0614
<i>BoostDropoutNet</i>	0.0480	0.0491

- ▶ La conclusión principal no depende fuertemente del criterio de selección.
- ▶ Para *BoostDropoutNet*, MMV obtiene un resultado levemente mejor.
- ▶ Esto sugiere que parte de su ventaja aparece en un régimen más tardío del entrenamiento.

Distribución de la mejor época

Imagen pendiente

imagenes_resultados/entrenamiento_principal/best_model/boxplot_mejor_epoca_best_mod

Modelo	MMV	Early
<i>OverFitNet</i>	7.8	7.8
<i>DropoutNet</i>	12.0	12.0
<i>DropConnectNet</i>	16.3	16.3
<i>BoostDropoutNet</i>	43.8	29.2

Lectura dinámica

BoostDropoutNet alcanza sus mejores configuraciones más tarde que las otras arquitecturas.

Imagen pendiente

imagenes_resultados/entrenamiento_principal/early_stopping/boxplot_mejor_epoca_earl

Curvas representativas de validación

Imagen pendiente

`imagenes_resultados/entrenamiento_principal/`

Imagen pendiente

`imagenes_resultados/entrenamiento_principal/`

- ▶ *OverFitNet* muestra deterioro tardío de validación.
- ▶ Dropout y DropConnect atenúan ese patrón.
- ▶ *BoostDropoutNet* mantiene una validación más estable en épocas tardías.

Resultado cualitativo clave

En *BoostDropoutNet* no se observa el ascenso tardío de pérdida de validación que sí aparece en las otras arquitecturas.

Imagen pendiente

imagenes_resultados/graficos_variando_p/comparison_error_test_best_model.png

- ▶ p controla la frecuencia de modulación o enmascaramiento.
- ▶ *BoostDropoutNet* muestra una región favorable alrededor de $p = 0.7$.
- ▶ La mejora no depende de un punto aislado: se mantiene en una zona amplia del rango explorado.

Conclusión

El valor seleccionado por grid search coincide con el entorno de mejor desempeño al ampliar el análisis.

Imagen pendiente

imagenes_resultados/graficos_variando_p/comparison_perdida_test_best_model.png

Imagen pendiente

imagenes_resultados/graficos variando
lambda/comparison_lambda_error_test_best_model.png

- ▶ λ controla la intensidad de la modulación multiplicativa.
- ▶ La región positiva contiene los mejores resultados de *BoostDropoutNet*.
- ▶ Valores negativos, especialmente cerca de $\lambda = -1$ sin normalización, degradan fuertemente el desempeño.

Interpretación

BoostDropout no es simplemente Dropout con otro nombre: λ introduce un grado de libertad nuevo y cambia el régimen de comportamiento.

Imagen pendiente

imagenes_resultados/graficos variando
lambda/comparison_lambda_perdida_test_best_model.png

Conclusión del protocolo principal

- 1 La regularización estocástica mejora sistemáticamente a la red base.
- 2 Dropout y DropConnect reducen el sobreajuste y obtienen resultados similares entre sí.
- 3 *BoostDropoutNet* supera a las tres arquitecturas de referencia en error y pérdida de test.
- 4 La ventaja se sostiene bajo MMV, *early stopping*, curvas temporales y análisis de sensibilidad.

Mensaje central

La modulación multiplicativa no binaria aparece como una estrategia efectiva de regularización en el escenario experimental estudiado.

¿Por qué usar autoencoders?

Imagen pendiente

15_autoencoder_architecture.png

Imagen sugerida de la tesis:

15_autoencoder_architecture.png

- ▶ Un autoencoder aprende a reconstruir su entrada.
- ▶ Permite observar representaciones internas y características aprendidas.
- ▶ En la tesis se usa como análisis complementario, no como benchmark principal.

Objetivo

Mirar si los mecanismos de regularización producen firmas cualitativas distintas en las representaciones.

Visualización de coadaptaciones

Imagen pendiente

imagenes_resultados/autoencoder/OverFitNet/imagenes_resultados/autoencoder/DropCon

Imagen pendiente

imagenes_resultados/autoencoder/DropCon

Imagen pendiente

imagenes_resultados/autoencoder/Dropout/coadimagenes_resultados/autoencoder/BoostDro

Imagen pendiente

imagenes_resultados/autoencoder/BoostDro

Decodificaciones desde neuronas latentes individuales

Imagen pendiente

imagenes_resultados/autoencoder/OverFitNet/singlen_latent_results/autoencoder/DropCon

Imagen pendiente

imagenes_resultados/autoencoder/DropCon

Imagen pendiente

imagenes_resultados/autoencoder/Dropout/singlen_latent_results/autoencoder/BoostDro

Imagen pendiente

imagenes_resultados/autoencoder/BoostDro

- ▶ Dropout tiende a mostrar detectores más localizados y menor coadaptación visual.
- ▶ DropConnect aparece en una posición intermedia.
- ▶ *BoostDropout* no replica exactamente la firma visual de Dropout.
- ▶ Esto sugiere que la mejora de *BoostDropoutNet* no debe interpretarse como una versión más intensa de Dropout.

Mensaje central

BoostDropout regulariza, pero probablemente mediante un mecanismo cualitativamente distinto al de la supresión binaria de activaciones.

Esparsidad representacional y paramétrica

Esparsidad de representaciones

Imagen pendiente

`imagenes_resultados/autoencoder/BoostDropout/sparsity.png`

- ▶ Se distinguen dos nociones: activaciones esparsas y pesos esparsos.
- ▶ El análisis complementa la comparación cuantitativa.
- ▶ No busca reemplazar el resultado principal de clasificación.

Uso en la defensa

Presentar este bloque como evidencia interpretativa, no como prueba definitiva del mecanismo.

Esparsidad en primera capa

Imagen pendiente

`imagenes_resultados/autoencoder/BoostDropout/first_layer_parameter_sparsity.png`

Qué podemos afirmar

- ▶ En el protocolo estudiado, *BoostDropoutNet* mejora a la red base.
- ▶ Supera a Dropout y DropConnect en las métricas principales.
- ▶ Muestra una dinámica de validación más estable.

Qué no podemos afirmar

- ▶ Superioridad universal.
- ▶ Validez automática para todas las arquitecturas.
- ▶ Generalización directa a todos los datasets o regímenes de entrenamiento.

Limitaciones metodológicas

- ▶ Se trabajó con un subconjunto de MNIST.
- ▶ La arquitectura fue una red densa *feed-forward* específica.
- ▶ La búsqueda de hiperparámetros fue acotada.
- ▶ La evaluación fue multisemilla, pero no exhaustiva.
- ▶ El análisis con autoencoders fue cualitativo y complementario.

Mensaje central

Estas limitaciones no debilitan el resultado; delimitan con precisión su alcance.

Conclusiones principales

- ❶ **Regularización efectiva:** *BoostDropoutNet* mejora a *OverFitNet* y mitiga el sobreajuste en el escenario estudiado.
- ❷ **Comparación favorable:** bajo el protocolo experimental, supera consistentemente a Dropout y DropConnect.
- ❸ **Mecanismo distinto:** su comportamiento sugiere una forma de regularización diferente, no una simple intensificación de Dropout.

Mensaje de defensa

La contribución central es abrir una dirección: estudiar regularización estocástica más allá de la supresión binaria.

- ▶ Evaluar *BoostDropout* en otras arquitecturas: CNNs, redes más profundas, modelos residuales.
- ▶ Probar otros datasets y problemas de mayor complejidad.
- ▶ Explorar de manera más amplia el espacio de p , λ y normalización.
- ▶ Analizar calibración probabilística y temperature scaling como diagnóstico posterior.
- ▶ Estudiar vínculos con física estadística, sistemas complejos y dinámica de perturbaciones multiplicativas.

Esta tesis propone pensar la regularización no solo como supresión aleatoria, sino como una intervención más general sobre la intensidad de las señales internas de una red neuronal.

Imagen pendiente

14_boostdropout_training.png

Muchas gracias.

Apéndice: ecuaciones clave de *BoostDropout*

$$m_j = \begin{cases} 1 + \lambda, & \text{con probabilidad } p, \\ 1, & \text{con probabilidad } 1 - p, \end{cases}$$

$$\tilde{h}_j = m_j h_j,$$

$$\mathbb{E}[m_j] = 1 + p\lambda,$$

$$\hat{m}_j = \frac{m_j}{1 + p\lambda} \Rightarrow \mathbb{E}[\hat{m}_j] = 1.$$

Caso límite

Para $\lambda = -1$, la máscara se vuelve binaria; con normalización adecuada se recupera la lógica de *inverted dropout*.

MMV

Early stopping

Modelo	Media	Mediana	Desv.	Mín.	Máx.	Modelo	Media	Mediana	Desv.	Mín.	Máx.
<i>OverFitNet</i>	.0687	.0681	.0023	.0655	.0726	<i>OverFitNet</i>	.0687	.0681	.0023	.0655	.0726
<i>DropoutNet</i>	.0609	.0616	.0036	.0547	.0672	<i>DropoutNet</i>	.0609	.0616	.0036	.0547	.0672
<i>DropConnectNet</i>	.0614	.0609	.0029	.0555	.0655	<i>DropConnectNet</i>	.0614	.0609	.0029	.0555	.0655
<i>BoostDropoutNet</i>	.0480	.0468	.0036	.0442	.0522	<i>BoostDropoutNet</i>	.0491	.0491	.0028	.0451	.0531